

分类型机器学习算法实战报告

—— 逻辑回归、决策树、随机森林与模型评价 ——

TASK5 量化策略课程

摘要

本报告系统介绍了分类型机器学习的三种经典算法——逻辑回归、决策树和随机森林，以及混淆矩阵、AUC、ROC曲线等模型评价指标的原理与含义。在此基础上，使用Python编程语言，分别对乳腺癌数据集（569个样本、27个特征）和股票收益数据集（20772个样本、17个特征）进行了完整的分类建模实验，包括数据加载、训练集与测试集划分、模型训练、AUC计算和ROC曲线绘制。实验结果表明，乳腺癌数据集上逻辑回归表现最佳（AUC=0.9977），而股票收益数据集上随机森林表现相对最好（AUC=0.6331），但整体预测效果有限，符合金融市场难以预测的客观规律。

目 录

第一部分 分类型机器学习算法

1.1 逻辑回归

1.2 决策树

1.3 随机森林

第二部分 模型评价指标

2.1 混淆矩阵

2.2 ROC曲线

2.3 AUC

第三部分 Python编程实战

3.1 数据准备

3.2 完整代码

3.3 代码解读

第四部分 结果展示与分析

4.1 乳腺癌数据集结果

4.2 股票收益数据集结果

第五部分 总结

第一部分 分类型机器学习算法

分类 (Classification) 是监督学习的核心任务之一：给定带标签的训练数据，学习一个从特征X到离散标签Y的映射关系。常用的分类算法包括逻辑回归、决策树、随机森林等，它们各有特点和适用场景。

1.1 逻辑回归 (Logistic Regression)

虽然名字里有"回归"，但逻辑回归是经典的分类算法，尤其适合二分类任务。其核心思想是通过Sigmoid函数将线性回归的输出映射到(0,1)区间，表示样本属于正类的概率。Sigmoid函数的数学表达式为：

$$\sigma(z) = 1 / (1 + e^{(-z)}), \text{ 其中 } z = w \cdot x + b$$

当 $P(Y=1|X) \geq 0.5$ 时，预测为正类 (1)，否则预测为负类 (0)。逻辑回归使用对数损失 (交叉熵损失) 作为损失函数：

$$L(w) = -(1/m) \cdot \sum [y \cdot \log(\sigma) + (1-y) \cdot \log(1-\sigma)]$$

逻辑回归的优点在于训练速度快、可解释性强、输出概率值便于调整阈值；缺点是只能学习线性决策边界，对非线性关系表现欠佳，且对特征尺度敏感 (需要进行标准化处理)。

1.2 决策树 (Decision Tree)

决策树是一种树形结构的分类器，通过对特征空间进行递归划分来预测样本标签。从根节点开始，选择信息增益最大或基尼系数最小的特征进行切分，递归构建子树，直到满足停止条件。常用的划分准则包括：

信息增益： $IG(D, A) = H(D) - H(D|A)$ (ID3/C4.5算法)

基尼系数： $Gini(D) = 1 - \sum p_k^2$ (CART算法)

决策树的优点是模型直观可解释、可视化方便、无需特征标准化、能学习非线性关系；缺点是容易过拟合 (需要剪枝)、对训练数据的小变化敏感、可能陷入局部最优。

1.3 随机森林 (Random Forest)

随机森林是集成学习 (Ensemble Learning) 的代表性算法，通过组合多棵决策树来提升整体性能。其采用自助采样 (Bootstrap Sampling) 从训练集中有放回地抽取多个子集，分别训练决策树，预测时采用多数投票 (分类) 或平均 (回归) 的方式整合结果。

随机森林的随机性来源于两个方面：

- (1) 样本随机：每棵树用不同的bootstrap样本训练；
- (2) 特征随机：每棵树分裂时只考虑特征的随机子集。

随机森林的优点是精度通常比单棵决策树高、抗过拟合能力强、可输出特征重要性、支持并行训练；缺点是模型可解释性差 (黑盒)、占用内存大、对高维稀疏数据效果一般。

第二部分 模型评价指标

2.1 混淆矩阵 (Confusion Matrix)

混淆矩阵是评估分类模型性能的基础工具，将预测结果按真实类别与预测类别的组合进行统计。对于二分类问题，混淆矩阵包含四个基本元素：

	预测为负类(0)	预测为正类(1)
真实负类(0)	TN (真负)	FP (假正)
真实正类(1)	FN (假负)	TP (真正)

由混淆矩阵可衍生出以下常用评价指标：

准确率 (Accuracy) = $(TP + TN) / (TP + FP + FN + TN)$

精确率 (Precision) = $TP / (TP + FP)$ ，即预测为正的样本中实际为正的比率

召回率 (Recall) = $TP / (TP + FN)$ ，即实际为正的样本中被正确识别的比率

F1分数 (F1-Score) = $2 \cdot (P \cdot R) / (P + R)$ ，即精确率与召回率的调和平均

在实际应用中，关注"宁可错杀不可放过"的场景（如疾病筛查）应重点考察召回率；关注"推荐必须精准"的场景（如垃圾邮件识别）应重点考察精确率；需要综合平衡两者时则使用F1值。

2.2 ROC曲线 (Receiver Operating Characteristic)

ROC曲线以假正率 (FPR) 为横轴、真正率 (TPR，即召回率) 为纵轴，展示了模型在不同分类阈值下的表现。其计算公式为：

$FPR = FP / (FP + TN)$, $TPR = TP / (TP + FN)$

绘制方法为：遍历所有可能的分类阈值，每个阈值对应一对(FPR, TPR)值，连成曲线。ROC曲线越靠近左上角，模型性能越好；对角线 ($y=x$) 代表随机分类器，曲线越偏离对角线，说明模型的分类能力越强。

2.3 AUC (Area Under Curve)

AUC即ROC曲线下方的面积，取值范围为[0, 1]。从概率角度理解，AUC表示随机抽取一对正负样本时，模型将正样本排在负样本前面的概率。例如AUC=0.85意味着：随机一对正负样本，模型有85%的概率给正样本打出更高的预测分数。

AUC范围	模型能力
0.50	等同于随机猜测
0.50 ~ 0.70	效果较差
0.70 ~ 0.85	效果一般
0.85 ~ 0.95	效果很好
0.95 ~ 1.00	效果优秀

第三部分 Python编程实战

3.1 数据准备

本案例同时使用两个数据集进行对比实验。乳腺癌数据集来自scikit-learn内置数据集的导出版本，包含569个样本、27个特征（细胞核形态指标），目标变量为0（恶性）或1（良性），其中良性357个、恶性212个。股票收益数据集包含20772个样本、17个特征（估值指标和增长率指标），目标变量Y为True（正收益）或False（负收益），其中正收益8389个、负收益12383个。

3.2 完整代码

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import (confusion_matrix, roc_curve,
                             roc_auc_score, accuracy_score, precision_score,
                             recall_score, f1_score)
# 1. 加载数据
df = pd.read_csv('model_data_cancer.csv')
feature_cols = [c for c in df.columns if c != 'target']
X = df[feature_cols].values
y = df['target'].values
# 2. 划分训练集/测试集 (7:3)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=42, stratify=y)
# 3. 特征标准化 (逻辑回归需要)
scaler = StandardScaler()
X_train_s = scaler.fit_transform(X_train)
X_test_s = scaler.transform(X_test)
# 4. 构建并训练模型
models = {
    '逻辑回归': LogisticRegression(max_iter=1000),
    '决策树': DecisionTreeClassifier(max_depth=5),
    '随机森林': RandomForestClassifier(n_estimators=100, max_depth=8)
}
# 5. 模型评估 + 6. 绘制ROC曲线
fig, ax = plt.subplots(figsize=(8, 6))
colors = ['#e74c3c', '#2ecc71', '#3498db']
for (name, model), color in zip(models.items(), colors):
    if name == '逻辑回归':
        model.fit(X_train_s, y_train)
        y_prob = model.predict_proba(X_test_s)[:, 1]
    else:
        model.fit(X_train, y_train)
        y_prob = model.predict_proba(X_test)[:, 1]
```

```
auc = roc_auc_score(y_test, y_prob)
fpr, tpr, _ = roc_curve(y_test, y_prob)
ax.plot(fpr, tpr, color=color, linewidth=2.5,
label=f'{name} (AUC = {auc:.4f})')
ax.plot([0,1], [0,1], 'k--', label='随机分类器')
ax.set_xlabel('假正率 (FPR)')
ax.set_ylabel('真正率 (TPR)')
ax.set_title('ROC 曲线对比')
ax.legend(); ax.grid(True, alpha=0.3)
plt.tight_layout()
plt.savefig('roc_curve.png', dpi=150)
```

3.3 代码解读

步骤	关键代码	作用
①数据加载	pd.read_csv()	读取CSV数据为DataFrame
②数据划分	train_test_split(stratify=y)	按7:3划分训练/测试集，保持类别比例
③特征标准化	StandardScaler()	缩放为均值0方差1，对逻辑回归尤为重要
④模型训练	model.fit(X_train, y_train)	用训练集拟合模型参数
⑤预测概率	predict_proba()[:,1]	取正类预测概率用于绘制ROC
⑥计算AUC	roc_auc_score(y_test, y_prob)	计算ROC曲线下面积
⑦绘制ROC	roc_curve(y_test, y_prob)	计算(FPR,TPR)序列并绘制曲线


第四部分 结果展示与分析

4.1 乳腺癌数据集结果

乳腺癌数据集共569个样本，按7:3比例划分后训练集398个、测试集171个。三种模型在测试集上的评估结果如下表所示：


模型	准确率	精确率	召回率	F1值	AUC
逻辑回归	0.9883	0.9907	0.9907	0.9907	0.9977
决策树	0.9357	0.9444	0.9533	0.9488	0.9268
随机森林	0.9415	0.9619	0.9439	0.9528	0.9907

图 1 乳腺癌数据集ROC曲线对比




如图1所示，三条ROC曲线均显著偏离对角线，其中逻辑回归的曲线最靠近左上角，AUC达到0.9977，接近完美分类。随机森林的AUC为0.9907，同样表现优异。决策树的AUC为0.9268，虽然略低于前两者，但仍然属于"效果优秀"的范畴。这表明乳腺癌数据集的特征与目标之间具有较强的可分性，三种模型均能有效识别良恶性肿瘤。

图 2 乳腺癌数据集混淆矩阵对比



如图2所示，逻辑回归在测试集上仅有2个样本被误判（1个假正、1个假负），准确率高达98.83%。决策树和随机森林分别有11个和10个误判样本。在医学诊断场景中，假负（将恶性误判为良性）的代价远高于假正，因此召回率尤为重要。逻辑回归的召回率达到99.07%，仅漏诊1例，表现最为可靠。

图 3 乳腺癌数据集评估指标对比



如图3所示，从五项指标的横向对比来看，逻辑回归在准确率、召回率、F1值和AUC四项上均最优，仅在精确率上略低于随机森林。决策树在各项指标上均处于末位，说明单棵决策树容易受到数据波动的影响。随机森林通过集成多棵树，有效提升了稳定性，各项指标均优于决策树。


综合分析：乳腺癌数据集三类模型均表现优异，AUC都在0.92以上。逻辑回归表现最好（AUC=0.9977），说明经过特征标准化后，特征与目标之间近似线性可分。随机森林紧随其后（AUC=0.9907），体现出集成学习的优势。

4.2 股票收益数据集结果

股票收益数据集共20772个样本，按7:3比例划分后训练集14540个、测试集6232个。三种模型在测试集上的评估结果如下表所示：


模型	准确率	精确率	召回率	F1值	AUC
逻辑回归	0.5956	0.4615	0.0072	0.0141	0.5561
决策树	0.6114	0.5396	0.2571	0.3482	0.6078
随机森林	0.6248	0.5727	0.2801	0.3762	0.6331

图 4 股票收益数据集ROC曲线对比




如图4所示，三条ROC曲线均较为接近对角线，AUC值在0.55至0.63之间，说明模型的分类能力仅略优于随机猜测。随机森林的曲线最优（AUC=0.6331），决策树次之（AUC=0.6078），逻辑回归最弱（AUC=0.5561）。这表明股票收益受多重复杂因素影响，仅凭历史财务指标难以稳定预测未来涨跌方向。

图 5 股票收益数据集混淆矩阵对比



如图5所示，逻辑回归的召回率极低（仅0.72%），几乎将所有样本预测为负类，说明线性模型在处理股票数据的复杂非线性关系时力不从心。决策树和随机森林的召回率分别为25.71%和28.01%，虽然有所改善但仍不理想。随机森林在保持较高准确率（62.48%）的同时，召回率和F1值均为三者最高，体现出其非线性拟合能力的一定优势。

图 6 股票收益数据集评估指标对比



如图6所示，随机森林在准确率、精确率、召回率、F1值和AUC五项指标上均优于其他两种模型。逻辑回归的F1值仅为0.0141，说明其在正类预测上几乎失效。整体来看，股票数据的各项指标均远低于乳腺癌数据集，反映了金融时间序列预测的高难度特征。

综合分析：股票数据集所有模型的AUC都在0.55至0.65之间，预测效果有限。这并非模型本身的问题，而是股票市场受宏观经济、政策、情绪、突发事件等多重因素影响，仅凭历史财务指标难以稳定预测未来收益——这也印证了"股票市场不可预测"这一业界共识。其中随机森林表现相对最好（AUC=0.6331），说明其非线性拟合能力有一定优势。

第五部分 总结

5.1 算法对比总结

维度	逻辑回归	决策树	随机森林
模型类型	线性分类器	非线性树模型	集成树模型
可解释性	高	较高	一般
训练速度	快	较快	中等
抗过拟合	强	弱	较强
预测精度	中	中	高
特征要求	需标准化	无需标准化	无需标准化
适用场景	线性可分问题	需要解释的简单任务	追求精度的复杂任务

5.2 评价指标选择建议

当类别分布平衡时，使用准确率和AUC即可较好地评估模型性能，如本任务的乳腺癌数据集。当类别分布不平衡时，准确率可能产生误导（如全预测为多数类即可获得高准确率），此时应重点关注F1值和AUC-PR曲线，关注少数类的识别效果。当模型需要输出概率而非硬标签时（如信用评分），AUC和对数损失更为合适，因为它们可以评估模型对不同样本的排序能力。

5.3 关键收获

第一，三种分类算法各有适用场景，随机森林在大多数情况下表现最稳健，是实际项目中的首选基线模型。

第二，ROC曲线与AUC是评估分类模型最常用、且不受分类阈值影响的指标，能够全面反映模型在不同决策阈值下的整体表现。

第三，金融数据预测本质上是非常困难的任务，AUC略高于0.5已说明模型捕捉到了微弱信号，不应期望通过简单的财务指标建模获得高精度的收益预测。

第四，特征工程和数据质量往往比模型选择更影响最终效果，在投入复杂模型之前，应充分做好数据清洗、特征筛选和特征构造工作。