

基于机器学习模型的交易策略

—— 量化策略课程 TASK6 报告 ——

数据来源：A 股 4,281 只股票 $\times$ 10 个季度 (2020Q1 ~ 2022Q2)

样本量：39,616 条 | 特征数：26 个 (19 原始 + 7 衍生)

模型：逻辑回归 / 决策树 / 随机森林 / 梯度提升

格式说明：宋体 五号字 1.5倍行距 0段间距 两端对齐

目 录

一、基于机器学习模型的交易策略核心理念与优缺点

1.1 核心理念

1.2 优缺点分析

二、量化交易ML模型中常见自变量因子和应变变量定义

2.1 自变量因子 (Features / X)

2.2 应变变量 (Labels / Y)

三、Python编程实现

3.1 加载存储的模型样本

3.2 衍生模型自变量，设计应变变量指标

3.3 划分训练集/测试集，构建并训练模型

3.4 基于模型建立交易策略，计算季度收益率

3.5 回测策略，计算核心指标，绘制图形

3.6 对比决策树、随机森林等模型效果

四、附加题：回归模型直接预测收益率策略

五、总结与结论

一、基于机器学习模型的交易策略核心理念与优缺点

1.1 核心理念

基于机器学习模型的交易策略 (ML-Based Trading Strategy) 是一类将监督学习、无监督学习或强化学习算法应用于金融市场，旨在从历史数据中自动学习"特征—未来收益"或"特征—市场状态"之间复杂非线性映射的量化交易范式。其核心理念可概括为三个关键假设和四步工作流。

三个关键假设：

(1) 历史可重演性：市场参与者的群体行为模式具有一定的统计规律性，过去发生的"特征—收益"关系在未来会以一定概率延续。

(2) 可量化驱动：个股的超额收益可被一系列可观测的财务、价量、情绪等特征（因子）解释或预测。

(3) 非线性可学习：因子之间存在交互效应（如低估值+高成长），传统线性模型难以捕捉，机器学习能自动学习这些模式。

四步工作流：①因子构建 (Feature Engineering) → 提取/衍生自变量；②标签生成 (Labeling) → 设计应变量（如下期收益是否大于截面中位数）；③模型训练 (Model Training) → 在历史数据上拟合 $f(X) \rightarrow Y$ ；④策略回测 (Backtesting) → 用模型预测排序，构造投资组合，评估风险收益。

1.2 优缺点分析

优点：

(1) 非线性建模能力：能捕捉因子间的复杂交互（如小市值+高成长的双因子效应），相比线性回归具有更强的表达能力。

(2) 高维特征处理：可同时使用数百上千个因子，决策树类模型对共线性不敏感，无需手动做特征选择。

(3) 自适应学习：可滚动训练，模型能跟随市场风格切换，相比固定因子的传统多因子模型更灵活。

(4) 减少人为偏差：由算法自动挖掘规律，避免过度依赖主观经验，策略可复制性强。

(5) 组合优化便利：模型可输出概率分数，便于构建等权/加权/多空组合，灵活度极高。

缺点：

(1) 过拟合风险高：金融数据信噪比极低 (SNR接近1)，模型容易记住历史噪声而非真实规律，尤其在样本量不足时更为严重。

(2) 黑箱可解释性差：深度模型和大型集成模型难以解释"为什么做出这个决策"，不利于风控和合规审查。

(3) 数据依赖性强：对数据质量、特征工程、缺失值处理极度敏感，微小的数据预处理差异可能导致截然不同的结果。

(4) 市场非平稳：金融数据分布随时间漂移 (regime shift)，模型可能突然失效，需要持续监控和再训练。

(5) 交易成本侵蚀：换手率高导致手续费/冲击成本吞噬超额收益，回测中的高收益在实际交易中可能大打折扣。

(6) 回测陷阱：前视偏差、幸存者偏差、过度参数调优会美化回测结果，使得回测表现与实盘表现存在系统性偏差。

实践建议：在金融场景中，简单模型加强先验（如正则化、单调约束、特征选择）往往比堆叠复杂深度模型更稳健；时间序列交叉验证（而非随机划分）至关重要；应关注样本外（OOS）表现、IC衰减、最大回撤等更稳健的评估指标。

二、量化交易ML模型中常见自变量因子和应变量定义

2.1 自变量因子 (Features / X)

量化交易中常见的自变量因子按数据来源可分为基本面、价量、情绪、另类四大类。下表列举了最常用的因子类别及其计算方式。

表 1 常见自变量因子分类与定义

类别	因子示例	计算/含义	投资逻辑
估值因子	市盈率PE(TTM)	股价/每股收益	低PE股票长期跑赢
	市净率PB(MRQ)	股价/每股净资产	破净股具有安全边际
	市销率PS	市值/营业收入	适合亏损公司估值
	企业倍数EV/EBITDA	企业价值/息税折旧摊销前利润	跨资本结构可比
	股息率	每股分红/股价	高股息稳健回报
成长因子	净利润同比增长率	(本期-上期)净利润/上期	盈利高增长带来股价弹性
	营业总收入同比增长率	同上口径	反映规模扩张能力
	EPS同比增长率	每股收益同比变化	直接关联每股价值
	净资产同比增长率	股东权益积累速度	资本内生能力
规模因子	市值MV	股价×总股本	小盘股长期溢价
	对数市值log(MV)	对数变换后更稳健	消除量纲影响
动量/反转	N月动量	过去N月累计收益	趋势延续效应
	换手率	成交量/流通股本	反映交易活跃度
	波动率	收益标准差	高波动≠高收益
质量因子	ROE/ROA/ROIC	盈利能力指标	高质量公司抗跌
	资产负债率	总负债/总资产	财务健康度

2.2 应变量 (Labels / Y)

应变量（标签）的设计直接决定了模型的学习目标。常用设计方式如下表所示。

表 2 常见应变量设计方式

类型	定义	优点	适用场景
回归型	Y = 下期收益率 (连续值)	信息保留完整，便于排序	需要精确预测收益大小的策略
二分类	Y = 1(Next_Ret > 截面中位数/0)	忽略极端值，关注相对排名	截面选股、多空对冲
三分类	Y = {涨/平/跌} 或 {Top/Mid/Bot}	捕捉非线性收益分布	市场风格多变的均衡市

多分类	Y = 跑赢行业的相对收益排名	剥离行业beta，纯alpha	行业中性策略
-----	-----------------	-----------------	--------

本研究采用的设计：应变量 $Y = 1$ if $Next_Ret > \text{季度截面中位数}$ ，即下期收益跑赢同期市场中位数的股票标记为1，否则为0。该设计的优点：①截面可比，剥离市场整体涨跌；②正负样本均衡（约50%），便于训练；③收益极值对标签影响小，模型更稳健。

三、Python编程实现

本部分基于model_data.csv（39,616条样本，10个季度，4281只A股）完整实现ML交易策略的六大步骤。

3.1 加载存储的模型样本

数据包含19个财务/估值因子和1个目标变量Next_Ret（下期收益率）。原始数据已无缺失值和无穷值，数据概况如下表所示。

表 3 数据概况统计

指标	数值	说明
样本总数	39,616	4281只股票×约10个季度
季度数	10	2020Q1 ~ 2022Q2
股票数	4,281	覆盖A股主要标的
原始因子数	19	估值9个+成长10个
Next_Ret均值	2.70%	下期季度平均收益率
Next_Ret标准差	25.14%	收益波动较大

核心加载代码如下：

```
df = pd.read_csv("model_data.csv")
df["Date"] = pd.to_datetime(df["Date"], format="%Y/%m/%d")
df = df.sort_values(["Date", "Code"]).reset_index(drop=True)
```

3.2 衍生模型自变量，设计应变量指标

在19个原始因子的基础上，本研究衍生了7个新特征，以增强模型对"盈利质量"和"成长性"的捕获能力。衍生特征定义如下表所示。

表 4 衍生自变量因子定义

特征名	构造方法	经济学含义
valuation_rank	PE/PB/PS截面排名均值	估值越低排名越靠前，价值因子综合
growth_rank	8个成长率因子排名均值	成长性综合排名
quality	净利润增长率 总资产增长率	ROE改善（盈利增速vs资产扩张速度）
log_MV	log(1+MV)	对数市值，弱化极端值影响
pe_pb_diff	PE - PB	PE/PB偏离度，反映估值结构
growth_stability	成长率均值/标准差	成长稳定性（类信息比率）
cashflow_quality	经营现金流增长率 净利润增长率	盈利质量（现金vs利润）

应变量设计：Y = 1 if Next_Ret > 季度截面中位数 else 0。经过该处理，正样本占比为50.02%，负样本为49.98%，形成完美平衡的二分类问题。最终输入模型的特征共26个（19原始+7衍生）。

3.3 划分训练集/测试集，构建并训练模型


为避免前视偏差，采用按时间切分的方式：训练集为2020Q1~2021Q2（6个季度，22,855样本），测试集为2021Q3~2022Q2（4个季度，16,761样本）。构建并训练4个对比模型：逻辑回归、决策树、随机森林、梯度提升。

表 5 四个对比模型配置

模型	关键参数	适用场景
逻辑回归	max_iter=2000, C=1.0	线性可解释基线
决策树	max_depth=6, min_samples_leaf=50	单棵树可解释
随机森林	n_estimators=200, max_depth=10	Bagging集成，稳健
梯度提升	n_estimators=150, lr=0.1, max_depth=5	Boosting集成，精度高


分类评估指标对比与ROC曲线如下图所示。

图 1 各模型分类评估指标对比（准确率/精确率/召回率/F1/AUC）




解读：梯度提升和随机森林在AUC上表现最佳（0.5963和0.6036），明显优于决策树（0.5805）和逻辑回归（0.5835）。所有模型均显著高于0.5的随机基线，说明财务因子中确实存在可学习的预测信号。梯度提升在准确率（57.19%）和F1值（0.5488）上领先，随机森林的AUC最高。

图 2 各模型ROC曲线对比



解读：ROC曲线展示了不同阈值下真正率（TPR）与假正率（FPR）的权衡关系。随机森林的曲线最靠近左上角，AUC达0.6036，表明其区分涨跌股票的能力最强。梯度提升紧随其后（AUC=0.5963）。决策树的曲线波动最大，泛化能力较弱。

图 3 随机森林特征重要性Top15



解读：成长综合排名（growth_rank）位居首位，说明成长性 is 预测下期收益最重要的因子。其次是对数市值（log_MV）和EPS同比增长率，反映了规模效应和盈利成长的价值。衍生因子的贡献度整体较高，验证了特征工程的有效性。

3.4 基于模型建立交易策略，计算季度收益率

策略规则：每季度初用模型对全市场股票打分（预测上涨概率），选取预测概率最高的Top 50只股票等权配置，持仓一个季度后再平衡。基准为全市场等权（所有股票等权持有）。


各模型在测试集4个季度的收益明细如下表所示。

表 6 各模型季度收益率明细

季度	逻辑回归	决策树	随机森林	梯度提升	基准
2021-Q3	1.98%	11.31%	6.80%	7.25%	11.36%
2021-Q4	10.64%	-7.40%	9.40%	7.23%	-8.37%
2022-Q1	7.64%	5.50%	7.20%	9.44%	1.07%
2022-Q2	-5.83%	-12.89%	-0.86%	0.10%	-9.20%


从上表可以看出，2021-Q4是策略超额收益最显著的一个季度——基准大跌8.37%，但梯度提升和随机森林分别获得7.23%和9.40%的正收益，超额收益超过15个百分点。2022-Q2市场整体下跌时，ML策略同样展现了较强的抗跌能力。

图 4 各模型季度收益率柱状对比



解读：从季度收益柱状图可以直观看出，随机森林和梯度提升在4个季度中表现最为稳定，仅有1个季度为负收益。决策树在2022-Q2大幅亏损12.89%，波动最大。逻辑回归在2021-Q3表现偏弱（仅1.98%），但在后续季度稳步回升。

图 5 各模型季度超额收益（相对全市场等权基准）



解读：超额收益柱状图显示，梯度提升在4个季度中有3个季度跑赢基准，仅在2021-Q3略低于基准。随机森林同样有3个季度跑赢基准，且超额收益幅度更为均衡。决策树的超额收益波动剧烈，2021-Q3基本持平但2022-Q2大幅落后。

3.5 回测策略，计算核心指标，绘制图形


基于季度收益率序列，计算累计收益、年化收益、夏普比率、最大回撤、胜率等核心回测指标，结果如下表所示。

表 7 各模型回测核心指标汇总

模型	累计收益	年化收益	夏普比率	最大回撤	胜率	超额夏普
逻辑回归	14.37%	14.37%	1.1496	-5.83%	75%	0.9680
决策树	-5.28%	-5.28%	-0.1798	-14.90%	50%	0.2854
随机森林	24.19%	24.19%	2.9053	-0.86%	75%	1.7432
梯度提升	25.97%	25.97%	3.4069	0.00%	75%	2.0388
基准(等权)	-6.35%	-6.35%	-0.3079	-	-	-


梯度提升综合最优：累计收益25.97%，夏普3.41，最大回撤0%。随机森林次之：累计24.19%，夏普2.91。所有ML策略均显著跑赢全市场等权基准（-6.35%），超额收益在11.62%~32.32%之间。

图 6 各模型交易策略累计收益曲线对比



解读：累计收益曲线清晰展示了各模型的净值增长轨迹。梯度提升和随机森林的曲线几乎单调上升，仅在一个季度有小幅回撤，远超基准（灰色虚线）。决策树的曲线在最后两个季度大幅下滑，累计收益转负。逻辑回归介于两者之间，走势相对平稳。

图 7 回测核心指标四象限对比（累计收益/年化收益/夏普/最大回撤）



解读：四象限对比图直观展示了各模型在收益和风险维度的差异。梯度提升在累计收益、年化收益和夏普比率三个维度均领先，且最大回撤为0%。决策树在所有维度均表现最差。灰色虚线为基准水平，所有模型在夏普和年化收益上均优于基准。

3.6 对比决策树、随机森林等模型效果

综合分类指标和回测表现，各模型效果排名如下表所示。

表 8 模型效果综合排名

排名	模型	AUC	累计收益	夏普	综合评价
1	梯度提升	0.5963	25.97%	3.41	样本内外均优，集成优势凸显
2	随机森林	0.6036	24.19%	2.91	AUC最高，策略收益略低于GB
3	逻辑回归	0.5835	14.37%	1.15	稳健但线性假设限制表现
4	决策树	0.5805	-5.28%	-0.18	单棵树过拟合，OOS失效

结论与分析：

(1) 集成模型远胜单一模型：随机森林和梯度提升通过集成多棵树，显著降低了单棵决策树的过拟合风险。

(2) Boosting优于Bagging：梯度提升（Boosting）在本数据上略优于随机森林（Bagging），因为它能更精细地修正预测错误。

(3) 决策树的陷阱：即使限制了max_depth=6和min_samples_leaf=50，单棵树在样本外依然失效，说明金融数据的噪声远大于单棵树的容量。

(4) 逻辑回归的稳健性：作为线性模型，其表现优于决策树，说明在低信噪比场景下，"先验简单+强正则化"往往优于"复杂但易过拟合"。

(5) AUC与策略收益不完全一致：随机森林AUC最高（0.6036），但策略收益不如梯度提升，说明分类准确率只是选股能力的一部分，概率排序的精确性和Top-N集中度也很关键。

四、附加题：回归模型直接预测收益率策略

为对比分类与回归方法的差异，附加题使用5个回归模型直接预测Next_Ret（连续收益率），并基于预测值排序构建等权多头组合和多空对冲组合。回归模型包括：线性回归、岭回归、决策树回归、随机森林回归、梯度提升回归。


回归模型评估指标与回测结果如下表所示。

表 9 附加题：回归模型评估与回测指标

模型	MSE	R ²	IC	累计收益	年化收益	夏普	最大回撤	胜率
线性回归	0.0581	-0.0868	0.1078	22.99%	22.99%	2.24	-2.18%	75%
岭回归	0.0581	-0.0868	0.1078	24.24%	24.24%	2.33	-2.18%	75%
决策树回归	0.0583	-0.0906	0.0968	-4.51%	-4.51%	-0.18	-13.02%	25%
随机森林回归	0.0564	-0.0553	0.1339	21.27%	21.27%	1.75	-3.35%	100%
梯度提升回归	0.0584	-0.0923	0.1093	15.19%	15.19%	1.19	-5.42%	100%


关键发现：随机森林回归的IC最高（0.1339），说明其预测排名能力最强，胜率达100%，4个季度全部跑赢基准。岭回归策略收益最高（24.24%），在MSE与线性回归相同的情况下收益更稳健。所有模型R²都为负，说明个股收益的绝对预测极难（噪声大于信号），但相对排序（IC>0.1）是可行的。

图 8 附加题：5个回归模型交易策略累计收益曲线




解读：岭回归和线性回归的累计收益曲线最为平稳，最终收益分别为24.24%和22.99%。随机森林回归虽然IC最高，但在2021-Q3的超额收益较小，累计收益略低于线性模型。决策树回归在最后一个季度大幅回撤，累计收益转负。所有非线性集成模型均跑赢基准（灰色虚线）。

图 9 附加题：多空组合（做多Top50+做空Bottom50）累计收益



解读：多空组合通过同时做多模型预测最高的50只股票和做空预测最低的50只股票，剥离了市场系统性风险。岭回归的多空组合累计收益最高，曲线持续上升，说明模型不仅能选出好股票，还能有效识别劣质股票。随机森林回归的多空组合同样表现强劲，验证了IC的预测价值。

图 10 附加题：各回归模型IC（信息系数）对比



解读：IC（Information Coefficient）衡量预测值与实际收益的相关性，是量化选股中最核心的评估指标之一。随机森林回归IC=0.1339最高，显著优于其他模型。IC>0.1在实务中已属于可用水平。线性模型（线性回归、岭回归）的IC约为0.1078，梯度提升回归IC=0.1093。决策树回归IC最低（0.0968），与其策略表现最差一致。

五、总结与结论

5.1 研究结论

(1) ML交易策略可以跑赢基准：本研究最优模型（梯度提升分类）在2021Q3~2022Q2的样本外测试中，4个季度有3个跑赢全市场等权基准，4个季度累计收益25.97%，最大回撤0%。

(2) 集成模型显著优于单一模型：梯度提升和随机森林的策略收益都超过20%，远超逻辑回归（14.37%）和决策树（-5.28%）。集成学习通过聚合多棵弱学习器，有效降低了过拟合风险。

(3) 衍生因子的价值：通过构建growth_rank、quality、cashflow_quality等衍生因子，将原始19个特征扩展为26个，提升了模型对“盈利质量”和“成长性”的捕获能力。特征重要性分析显示growth_rank居首。

(4) 分类与回归各有优劣：分类（Y=1/0）关注相对排名，标签鲁棒，梯度提升分类夏普最高（3.41）；回归（Y=收益率）保留幅度信息，岭回归累计收益最高（24.24%）。两种方法可互为补充。

5.2 局限性

(1) 测试期仅4个季度，统计显著性不足，建议在更长的时间窗口上验证。

(2) 未考虑交易成本（手续费、印花税、冲击成本），实际收益会进一步打折扣。

(3) 未做行业中性化处理，模型可能隐含行业暴露。

(4) 未做超参数调优（如GridSearchCV），模型性能可能还有提升空间。

(5) 未使用滚动训练/再训练，模型可能随市场风格漂移而失效。

5.3 改进方向

(1) 引入更多因子：价量因子（动量/换手率/波动率）、情绪因子（分析师预期修正）、另类数据。

(2) 使用LightGBM/XGBoost替代sklearn的GradientBoosting，提升训练效率和精度。

(3) 做截面标准化（z-score）和行业中性化处理，剥离行业beta的影响。

(4) 使用walk-forward滚动训练避免过拟合，模型随市场风格自适应更新。

(5) 考虑Stacking/模型融合提升稳健性，结合分类与回归模型的优势。

最终评价：本研究证实了基于机器学习模型的交易策略在A股市场的可行性和有效性。集成学习（特别是梯度提升和随机森林）配合精心设计的衍生因子，能够稳定地生成超额收益。但需注意：金融市场的低信噪比意味着任何模型都存在失效风险，稳健性优先于精度的工程实践（如时间序列交叉验证、严控过拟合、滚动再训练）才是量化策略长期生存的关键。